

Étape 1 : rapport d'exploration des sources de données

Projet 12 : Extrayez des données multimodales de sites web (CheckIt.AI)

1. Objectif

CheckIt.AI veut constituer une base de publications d'actualité avec du texte et des images pour entraîner un détecteur de fake news. Ce rapport liste les sources que j'ai étudiées, leurs caractéristiques et la méthode d'extraction proposée pour chacune.

2. Données à récupérer

Champs indispensables pour chaque publication :

- le texte (titre et contenu ou résumé)
- la date de publication
- l'URL de la publication

L'image est récupérée dans la même entrée quand elle existe, mais les publications sans image sont gardées.

Champs secondaires utiles :

- le nom de la source et le nom de domaine
- la langue
- l'auteur
- la fiabilité déclarée de la source, si elle existe
- le label vrai/faux, si la source en fournit un

Les fake news multimodales les plus courantes sont les images sorties de leur contexte, les images retouchées ou générées par IA, et les titres qui ne correspondent pas à l'image. C'est pour ça que le texte et l'image doivent rester dans la même entrée.

3. Sources étudiées

Source	Type	Données	Format	Langue	Labels	Extraction
NewsData.io	API d'actualité	texte + image	JSON	multilingue (dont fr)	aucun	API REST (requests)
News API	API d'actualité	texte + image	JSON	14 langues (dont fr)	aucun	API REST (requests)
Flux RSS Le Monde, franceinfo	RSS	texte + image	XML	fr	aucun	feedparser
Flux RSS Les Décodeurs, 20 Minutes Fake Off	RSS (fact-checking)	texte + image	XML	fr	verdict dans le texte	feedparser
Le Gorafi	site satirique	texte + image	HTML	fr	satire (tout le site)	scraping (requests + BeautifulSoup)
Google Fact Check Tools API	API de fact-checking	texte (image via le lien de l'article)	JSON	multilingue (dont fr)	verdict de fact-checkers	API REST (requests)
Fakeddit	dataset	texte + image	TSV	en	2, 3 ou 6 classes	téléchargement + pandas
FakeNewsNet	dataset	texte + image (via le crawler)	CSV	en	fake/real (PolitiFact, GossipCop)	téléchargement + crawler
MediaEval Image Verification Corpus	dataset	image + identifiant de tweet	TXT	surtout en	fake/real vérifiés à la main	téléchargement
API Reddit	réseau social	texte + image	JSON	multilingue	aucun	API REST (PRAW)

Remarques par source :

- NewsData.io : 200 crédits par jour en gratuit (10 articles par crédit), 12 h de retard, pas de texte complet. Le champ source_priority classe les sources selon leur trafic et leur fiabilité.
- News API : 100 requêtes par jour en gratuit, 24 h de retard, contenu coupé à 200 caractères. L'offre gratuite est réservée au développement.
- Flux RSS de médias : gratuits et sans clé, avec titre, résumé, date et image.
- Flux RSS de fact-checking : même format. Le verdict n'est pas dans un champ séparé et certains articles ne sont pas des vérifications (quiz, graphiques). Le flux d'AFP Factuel n'était pas accessible.
- Le Gorafi : son flux RSS ne contient pas d'image, il faut aller la chercher sur la page de l'article. Le robots.txt autorise les articles.
- Google Fact Check : les verdicts viennent de fact-checkers (AFP, Les Décodeurs, PolitiFact...). Ils sont en texte libre (« Faux », « Trompeur »...) et il faudrait les regrouper. La clé API Google est gratuite.
- Fakeddit : plus d'un million de posts Reddit, dont une partie avec image. Le label dépend du subreddit d'origine, les posts ne sont pas vérifiés un par un.
- FakeNewsNet : le CSV contient seulement l'URL et le titre. Le texte et les images se récupèrent par scraping avec le script fourni, et beaucoup de liens sont anciens. La partie Twitter demande

l'API X, qui est payante.

- MediaEval : le texte des tweets n'est pas fourni, seulement leurs identifiants.
- Reddit : depuis novembre 2025, tout nouvel accès à l'API doit être validé par Reddit, ce qui peut prendre plusieurs semaines.

Sources écartées : le dataset Fake and Real News de Kaggle (texte seulement, pas d'image) et le dataset Weibo (en chinois).

Le scraping est utilisé seulement pour Le Gorafi, après vérification du robots.txt. Les pages sont en HTML simple, requests et BeautifulSoup suffisent sans passer par Scrapy ou Selenium.

4. Fiabilité des labels

Un label doit dire si une information est fausse, pas si elle est contestée. Une opinion controversée n'est pas de la désinformation.

Les labels les plus fiables sont ceux qui viennent de fact-checkers (Google Fact Check, FakeNewsNet, MediaEval). Ceux de Fakeddit sont moins précis, et sa classe Satire/Parody ne correspond pas à de la désinformation. Les API d'actualité et les flux RSS n'ont pas de label.

5. Droits d'usage

- News API gratuite : développement uniquement
- Flux du Monde : usage personnel uniquement (mention dans le flux)
- Reddit : accès sur validation, usage commercial soumis à accord
- Le Gorafi : pas de règle de réutilisation trouvée, usage éducatif uniquement et sur peu d'articles
- Les textes et les images restent la propriété des éditeurs et ne sont pas republiés
- Les noms d'auteurs sont des données personnelles (RGPD), je garde seulement les champs utiles

6. Choix des sources et format de sortie

Pour le pipeline, je retiens NewsData.io et les flux RSS du Monde, de franceinfo, des Décodeurs et de 20 Minutes. News API sert de solution de secours. J'ajoute quelques articles du Gorafi, récupérés par scraping. Pour les labels, Fakeddit est le dataset le plus simple à utiliser.

Chaque publication est enregistrée en JSON avec les champs suivants : id, source, domaine, url, titre, texte, image_url, image_path, date_publication, langue, auteur, fiabilite_source, label. L'id est un hash de l'URL, donc un même article garde toujours le même id. Les images sont enregistrées dans un dossier à part, avec l'id de la publication comme nom de fichier. Pour une publication sans image, image_url et image_path restent vides.

Après nettoyage, les données sont exportées en Parquet, qui garde les types (dates, entiers), puis chargées dans une base PostgreSQL : le schéma est fixe et la clé sur l'id évite les doublons d'une collecte à l'autre.

7. Liens

- NewsData.io : <https://newsdata.io/documentation>
- News API : <https://newsapi.org/docs>
- Google Fact Check Tools API : <https://developers.google.com/fact-check/tools/api>
- Fakeddit : <https://github.com/entitize/Fakeddit>
- FakeNewsNet : <https://github.com/KaiDMML/FakeNewsNet>
- MediaEval Image Verification Corpus : <https://github.com/MKLab-ITI/image-verification-corpus>
- Le Gorafi : <https://www.legorafi.fr> (robots.txt : <https://www.legorafi.fr/robots.txt>)
- Reddit, Responsible Builder Policy : <https://support.reddithelp.com/hc/en-us/articles/42728983564564-Responsible-Builder-Policy>
- Flux RSS : <https://www.lemonde.fr/rss/une.xml>, <https://www.franceinfo.fr/titres.rss>,
https://www.lemonde.fr/les-decodeurs/rss_full.xml, <https://www.20minutes.fr/feeds/rss-fake-off.xml>