


Étape 4 : preuves d'exécution du DAG Airflow

Projet 12 : Extrayez des données multimodales de sites web (CheckIt.AI)

Le DAG `etl_multimodal_news` tourne en local dans Airflow 3.3.2, lancé avec Docker Compose. Il enchaîne trois extractions en parallèle, la transformation, puis le chargement dans une base PostgreSQL.


1. Le DAG dans Airflow

Le DAG est activé et planifié tous les jours à minuit UTC (`0 0 * * *`). La dernière exécution a réussi.




2. Vue graphhe

Les trois extractions (NewsData, flux RSS, Le Gorafi) tournent en parallèle, puis viennent transform et load. Toutes les tâches sont des PythonOperator.




3. Vue grille

Trois exécutions, toutes les tâches ont réussi. Aucune tâche ni exécution en échec sur les dernières 24 heures.




4. Log de la tâche load

Le chargement ajoute ou met à jour les articles selon leur id : 221 articles envoyés, 221 au total dans la table.



5. Log de la tâche extract_newsdata

Les logs des scripts d'extraction apparaissent dans Airflow. Sur 44 articles récupérés, 14 sont écartés parce qu'il leur manque le titre ou le texte. Parmi les 30 gardés, 8 n'ont pas d'image exploitable (pas d'image ou lien refusé) et sont gardés sans image.



6. Contenu de la base

Requête sur la table articles de la base checkit-db : 221 articles répartis entre les 6 sources, dont 8 sans image.

nom_source	articles	sans_image
Les Décodeurs	20	0
NewsData.io	84	8
franceinfo	47	0
20 Minutes Fake Off	20	0
Le Gorafi	11	0
Le Monde	39	0
(6 rows)		