

Étape 5 : plan de monitoring du pipeline

Projet 12 : Extrayez des données multimodales de sites web (CheckIt.AI)

1. Objectif

Le pipeline tourne seul chaque jour et ses données alimentent le futur détecteur de fake news de CheckIt.AI. Un pipeline en panne, c'est un modèle entraîné sur des données périmées. Ce plan décrit ce qu'on surveille, à partir de quels seuils on réagit et à quelle fréquence on vérifie.

2. Ce qui est automatisé

- le DAG `etl_multimodal_news` tourne chaque jour à minuit UTC (2 h en France)
- si une tâche échoue, Airflow la relance une fois, 5 minutes plus tard
- si une extraction échoue malgré ce nouvel essai, la transformation et le chargement continuent avec les autres sources
- chaque tâche enregistre ses chiffres (nombre d'articles, durée, crédits utilisés) dans la table `pipeline_metrics`
- la dernière tâche, `controle_qualite`, compare ces chiffres aux seuils ci-dessous. En cas de problème critique, elle échoue et l'exécution apparaît en rouge dans Airflow
- les logs de chaque tâche sont gardés dans le dossier `logs/` et consultables dans l'interface Airflow

3. Indicateurs et seuils

Les seuils sont définis à un seul endroit (`src/config.py`) et utilisés à la fois par la tâche `controle_qualite` et par le tableau de bord.

Problèmes critiques, l'exécution passe en rouge dans Airflow :

- une extraction a échoué après le nouvel essai
- aucun article chargé en base

Alertes, message d'avertissement dans les logs et en orange sur le tableau de bord :

- moins de 60 % d'articles valides pour une source
- moins de 80 % d'articles avec une image
- exécution de plus de 5 minutes (environ 30 secondes en temps normal)
- plus de 150 crédits NewsData utilisés dans la journée (quota gratuit de 200)

Le tableau de bord signale aussi en rouge un pipeline qui n'a pas tourné depuis plus de 26 heures. Ce cas ne peut pas être vu par Airflow, puisqu'aucune tâche ne s'exécute. L'espace disque des images et la taille de la base sont suivis sans seuil.

4. Que faire en cas de problème

- extraction en échec : lire le log de la tâche dans Airflow. Une coupure réseau ou un site indisponible se règle souvent à l'exécution suivante. Si l'erreur revient plusieurs jours, vérifier la source (clé API, quota, changement de structure du site pour Le Gorafi)
- aucun article chargé : vérifier que le conteneur checkit-db tourne et que la connexion checkit_db fonctionne
- taux d'articles valides en baisse : regarder si la source a changé son format (champ vide ou renommé)
- quota NewsData presque atteint : réduire NEWSDATA_MAX_PAGES dans src/config.py et éviter les lancements manuels
- pipeline arrêté : vérifier que Docker Desktop et les conteneurs Airflow sont démarrés

Une fois le problème corrigé, on relance l'exécution depuis l'interface Airflow (bouton Déclencher).

5. Fréquence des vérifications

- chaque jour, automatiquement : exécution du DAG et contrôle qualité
- chaque jour, quelques secondes : coup d'œil au bandeau « État du pipeline » du tableau de bord
- chaque semaine : évolution des durées et des taux sur le tableau de bord, espace disque
- chaque mois : mises à jour d'Airflow et des bibliothèques, suppression des anciens logs

6. Limites

- aucune alerte n'est envoyée par e-mail : il faut ouvrir Airflow ou le tableau de bord pour voir un problème. En production, on configurerait l'envoi d'e-mails d'Airflow ou une notification sur la messagerie de l'équipe
- les crédits NewsData sont comptés à partir des exécutions du DAG. Un appel fait à la main, depuis un notebook par exemple, n'est pas compté